

UNIDADE 3 — TRABALHOS PRÁTICOS EM DUPLA REGRAS, TEMAS, METODOLOGIA E CRITÉRIOS

Disciplina	ELE 606 — Tópicos em Inteligência Artificial
Natureza da atividade	Projetos práticos com implementações individuais ou em dupla, com perfil de pesquisa aplicada
Período de desenvolvimento	10/06 a 30/06
Apresentações	01/07 e 08/07
Professor	Prof. José Alfredo F. Costa

1. Finalidade da Unidade 3

A Unidade 3 foi organizada para que os alunos desenvolvam projetos com maior profundidade técnica e analítica, aproximando a disciplina de uma lógica de pesquisa aplicada, experimentação comparativa e documentação reprodutível.

Os trabalhos deverão combinar processamento e análise de textos, experimentos com classificação e/ou clustering, estudo de embeddings, uso de APIs e discussão crítica dos resultados. A proposta é que as duplas avancem além de uma execução mecânica de código, produzindo análise, interpretação e reflexão metodológica.

Também se deseja estimular uma postura mais próxima do que se espera em projetos científicos e tecnológicos: definição do problema, escolha de bases de dados, construção de pipeline, comparação entre métodos, métricas, visualizações, análise de erros, limitações e continuidade.

2. Regras gerais obrigatórias

- Todos os trabalhos serão feitos em dupla.
- Cada dupla deverá usar no mínimo 2 bases de dados textuais.
- Cada projeto deverá comparar 3 algoritmos, abordagens ou configurações ou mais, preferencialmente com 2 métodos mais simples/clássicos e 1 mais recente ou mais avançado.
- Cada dupla deverá discutir pelo menos 2 tipos de embeddings, sendo um deles vetorial baseado em LLMs, Transformers, Sentence Transformers ou abordagem similar.
- Cada projeto deverá incluir algum uso de API para explicar, refinar, justificar, resumir, reordenar resultados ou enriquecer a análise.
- O trabalho deverá conter pré-processamento textual e discussão do impacto dessas escolhas nos resultados.

- Os resultados deverão ser analisados com métricas, visualizações, interpretação crítica e comparação entre as alternativas testadas.
- Será valorizada a organização reprodutível: notebook principal, scripts auxiliares, README ou seção metodológica clara, parâmetros principais e registro das bases utilizadas.

3. Estrutura mínima esperada

Seção / Item	Conteúdo esperado
1. Título e problema	Tema claro, com pergunta ou objetivo de pesquisa/aplicação.
2. Bases de dados	Descrição de pelo menos 2 bases textuais, com justificativa de escolha.
3. Pré-processamento	Limpeza, normalização, tokenização ou outras estratégias adotadas.
4. Representações textuais	Uso de TF-IDF e/ou embeddings; comparação entre pelo menos 2 embeddings.
5. Modelos / algoritmos	Teste de 3 algoritmos/abordagens ou mais, com parâmetros centrais registrados.
6. Avaliação	Métricas adequadas, tabelas comparativas, gráficos, matrizes de confusão, análise qualitativa ou análise de clusters.
7. Uso de API	Emprego de API para explicação, enriquecimento ou melhoria do pipeline.
8. Discussão	Interpretação dos resultados, análise de erros, trade-offs, limitações e observações metodológicas.
9. Conclusão	Síntese final e possibilidades de continuidade.
10. Apresentação oral	Material visual claro para seminário, com foco em resultados e aprendizado.

4. Sugestões de bases de dados

- Planilha de notícias em 6 classes, especialmente a coluna Texto Expandido.
- Bases textuais públicas do Kaggle.
- 20 Newsgroups.
- Bases públicas de sentimentos, spam, reviews, fake news, notícias temáticas, tweets, textos técnicos ou jurídicos públicos.
- Outras bases abertas e adequadas ao escopo do projeto, desde que documentadas pela dupla.

5. Temas sugeridos para os projetos

Tema 1 — Classificação textual multibase com comparação entre representações

Comparar o desempenho de classificadores em duas bases textuais distintas, usando ao menos uma representação clássica e uma representação baseada em embeddings mais avançados. Espera-se comparação entre modelos, análise de generalização entre bases, matrizes de confusão e discussão sobre estabilidade dos resultados.

Recomendação: a dupla deve testar pelo menos 3 abordagens ou algoritmos, trabalhar com 2 bases, discutir 2 tipos de embeddings e empregar alguma API como apoio à explicação, refinamento ou interpretação dos resultados.

Tema 2 — Clustering de textos com comparação entre TF-IDF e embeddings

Investigar como diferentes espaços vetoriais afetam agrupamentos textuais. A dupla poderá comparar K-Means, Agglomerative e DBSCAN/HDBSCAN, além de combinar clustering com PCA, t-SNE e UMAP para visualização e interpretação dos grupos.

Recomendação: a dupla deve testar pelo menos 3 abordagens ou algoritmos, trabalhar com 2 bases, discutir 2 tipos de embeddings e empregar alguma API como apoio à explicação, refinamento ou interpretação dos resultados.

Tema 3 — Redução de dimensionalidade e visualização de classes e clusters

Estudar como técnicas de projeção podem revelar estruturas latentes em bases textuais. A dupla deverá comparar ao menos duas formas de representação textual e diferentes técnicas de redução, discutindo separação visual, coerência semântica e perda de informação.

Recomendação: a dupla deve testar pelo menos 3 abordagens ou algoritmos, trabalhar com 2 bases, discutir 2 tipos de embeddings e empregar alguma API como apoio à explicação, refinamento ou interpretação dos resultados.

Tema 4 — Busca semântica e recuperação de documentos semelhantes

Construir um sistema simples de recuperação textual e comparar busca lexical, busca por TF-IDF e busca por embeddings. A dupla poderá usar API para re-ranking, sumarização dos resultados ou explicação da relevância dos documentos recuperados.

Recomendação: a dupla deve testar pelo menos 3 abordagens ou algoritmos, trabalhar com 2 bases, discutir 2 tipos de embeddings e empregar alguma API como apoio à explicação, refinamento ou interpretação dos resultados.

Tema 5 — Classificação com LLMs via API versus modelos clássicos

Comparar um pipeline clássico de classificação textual com uma estratégia apoiada por LLM via API, usando zero-shot ou few-shot. O foco deverá ser desempenho, consistência, qualidade das justificativas, custo aproximado e limitações da abordagem.

Recomendação: a dupla deve testar pelo menos 3 abordagens ou algoritmos, trabalhar com 2 bases, discutir 2 tipos de embeddings e empregar alguma API como apoio à explicação, refinamento ou interpretação dos resultados.

Tema 6 — RAG simples com bases textuais públicas

Montar um pipeline de chunking, embeddings, recuperação top-k e resposta com LLM, comparando resposta sem contexto e com contexto. A dupla deverá analisar grounding, qualidade da resposta, possíveis alucinações e impacto do número de trechos recuperados.

Recomendação: a dupla deve testar pelo menos 3 abordagens ou algoritmos, trabalhar com 2 bases, discutir 2 tipos de embeddings e empregar alguma API como apoio à explicação, refinamento ou interpretação dos resultados.

Tema 7 — Sensibilidade do pré-processamento em NLP

Investigar como diferentes estratégias de limpeza e transformação textual afetam classificação e clustering. A dupla deverá testar múltiplas variantes de pré-processamento e discutir o efeito dessas escolhas sobre desempenho, robustez e semântica.

Recomendação: a dupla deve testar pelo menos 3 abordagens ou algoritmos, trabalhar com 2 bases, discutir 2 tipos de embeddings e empregar alguma API como apoio à explicação, refinamento ou interpretação dos resultados.

Tema 8 — Classificação e clustering em pipeline híbrido

Explorar a combinação de clustering e classificação, observando se a organização prévia dos textos em grupos pode ajudar a reduzir escopo, melhorar interpretação ou apoiar a etapa supervisionada. O uso de API pode ajudar a nomear ou interpretar clusters.

Recomendação: a dupla deve testar pelo menos 3 abordagens ou algoritmos, trabalhar com 2 bases, discutir 2 tipos de embeddings e empregar alguma API como apoio à explicação, refinamento ou interpretação dos resultados.

Tema 9 — API experimental de NLP com múltiplos serviços

Transformar o experimento em um pequeno artefato reutilizável, com API em Flask ou FastAPI. A dupla pode implementar rotas como classificar texto, buscar similares, resumir ou explicar resultados, documentando o pipeline e as escolhas realizadas.

Recomendação: a dupla deve testar pelo menos 3 abordagens ou algoritmos, trabalhar com 2 bases, discutir 2 tipos de embeddings e empregar alguma API como apoio à explicação, refinamento ou interpretação dos resultados.

Tema 10 — Framework experimental de NLP com representação intermediária

Organizar um projeto modular com ingestão, pré-processamento, embeddings, classificação/clustering, visualização, API e registro de resultados. O objetivo é criar um pequeno framework experimental reproduzível, com pipeline claro, tabelas comparativas, logs e documentação.

Recomendação: a dupla deve testar pelo menos 3 abordagens ou algoritmos, trabalhar com 2 bases, discutir 2 tipos de embeddings e empregar alguma API como apoio à explicação, refinamento ou interpretação dos resultados.

6. Entregáveis recomendados

- Notebook principal ou conjunto organizado de scripts.
- Relatório curto ou seção final bem documentada no notebook.
- Tabelas, gráficos e figuras principais.
- Registro das bases utilizadas e dos parâmetros mais relevantes.
- Material de apresentação para o seminário.
- Conclusões, limitações e possíveis extensões.

7. Critérios sugeridos de avaliação

Critério	Descrição	Peso sugerido
Definição do problema e bases	Clareza do objetivo, escolha das bases e justificativa.	15%
Metodologia	Qualidade do pipeline, pré-processamento, embeddings e algoritmos testados.	25%
Resultados e comparação	Métricas, visualizações, comparação entre abordagens e consistência experimental.	25%
Análise crítica	Discussão de erros, limitações, trade-offs e qualidade da interpretação.	20%
Apresentação e organização	Clareza do material, documentação e comunicação oral.	15%

8. Observação final

O objetivo da Unidade 3 é estimular projetos mais robustos, comparativos e reflexivos. Não basta apenas rodar modelos: será importante justificar escolhas, comparar alternativas, interpretar resultados, discutir limitações e mostrar aprendizagem ao longo do processo.

Atenciosamente,

Prof. José Alfredo F. Costa

Temas aprofundados

1. Classificação textual multibase com comparação entre representações

Pergunta central: como diferentes formas de representar textos afetam a classificação em bases de domínios distintos?

Escopo:

- usar a base de notícias em 6 classes + mais 1 base pública;
- comparar pelo menos:
 - Naive Bayes,
 - Logistic Regression ou SVM,
 - um classificador com embeddings;
- comparar pelo menos 2 embeddings;
- incluir variações de pré-processamento;
- usar API para gerar explicações dos erros ou justificativas das classes.

Resultados esperados:

- tabela comparativa por base;
- matriz de confusão;
- análise de generalização entre bases;
- discussão sobre estabilidade dos modelos.

Profundidade de pesquisa: esse tema dialoga bem com a ideia de **baselines, comparação justa, validação modular e métricas multicamadas**.

2. Clustering e redução de dimensionalidade em textos: comparação entre espaços vetoriais

Pergunta central: clusters formados em TF-IDF e em embeddings semânticos se comportam da mesma forma?

Escopo:

- usar 2 bases textuais;

- comparar:
 - K-Means,
 - Agglomerative,
 - DBSCAN ou HDBSCAN;
- comparar ao menos 2 embeddings;
- usar PCA, t-SNE e/ou UMAP;
- usar API para ajudar a rotular semanticamente os clusters ou resumir seus conteúdos.

Resultados esperados:

- visualizações 2D;
- comparação entre separação visual e coerência semântica;
- análise de silhouette score ou métricas similares;
- interpretação qualitativa dos grupos.

Profundidade de pesquisa: excelente para discutir **representação intermediária, agrupamento, repertórios contextuais e visualização de padrões recorrentes**.

3. Busca semântica multibase e avaliação de recuperação

Pergunta central: embeddings diferentes mudam significativamente a qualidade da recuperação textual?

Escopo:

- usar 2 bases textuais;
- comparar:
 - busca lexical simples,
 - TF-IDF + similaridade,
 - embeddings + similaridade;
- testar pelo menos 2 embeddings;
- usar API para re-ranking, explicação da relevância ou sumarização dos top-k resultados.

Resultados esperados:

- comparação top-k;
- análise qualitativa de relevância;
- relatório de casos bons e ruins;
- discussão sobre busca híbrida.

Profundidade de pesquisa: alinha-se muito com **recuperação semântica, embeddings, base vetorial experimental e busca híbrida**.

4. RAG comparativo com bases textuais públicas

Pergunta central: o contexto recuperado melhora de fato a qualidade das respostas de um LLM?

Escopo:

- usar 2 bases textuais;
- montar pipeline de:
 - chunking,
 - embeddings,
 - recuperação top-k,

- resposta com LLM;
- comparar:
 - resposta sem contexto,
 - resposta com contexto,
 - resposta com contexto + re-ranking ou filtragem;
- testar 2 embeddings;
- usar API de LLM como núcleo explicativo.

Resultados esperados:

- respostas comparadas;
- análise de grounding;
- observação de alucinação;
- comparação entre top-3, top-5 e top-10.

Profundidade de pesquisa: esse tema está diretamente ligado ao eixo de **RAG controlado, contexto reduzido, logs, rastreabilidade e revisão crítica**.

5. Comparação entre modelos clássicos e LLMs para classificação e explicação

Pergunta central: quando o LLM agrega valor em relação ao pipeline clássico?

Escopo:

- usar 2 bases;
- comparar pelo menos:
 - Naive Bayes,
 - SVM ou Logistic Regression,
 - classificação via API com zero-shot ou few-shot;
- testar 2 embeddings;
- usar API para gerar explicações e justificativas das previsões.

Resultados esperados:

- comparação de desempenho;
- custo e latência aproximados;
- qualidade das explicações;
- análise de consistência.

Profundidade de pesquisa: conversa com a discussão do projeto do André sobre **o que o LLM de fato agrega além de simplesmente “gerar código ou resposta”** e com a necessidade de **comparar com baselines reais**.

6. Pré-processamento, robustez e sensibilidade em NLP

Pergunta central: até que ponto o desempenho depende mais do pré-processamento do que do algoritmo?

Escopo:

- usar 2 bases;
- comparar pelo menos 3 algoritmos;
- testar cenários como:
 - texto bruto,
 - remoção de stopwords,
 - stemming/lemmatização,
 - normalização adicional;
- comparar 2 embeddings;
- usar API para comentar automaticamente exemplos de erros ou gerar hipóteses sobre os resultados.

Resultados esperados:

- tabela comparativa de pipelines;
- análise de robustez;
- discussão do trade-off entre limpeza e perda de sinal semântico.

Profundidade de pesquisa: tema muito bom para mostrar maturidade metodológica, porque força o aluno a discutir **dados, ruído, preparação, métricas e limites experimentais**.

7. Classificação + clustering em pipeline híbrido

Pergunta central: clustering pode ajudar a organizar melhor a etapa de classificação?

Escopo:

- usar 2 bases;
- testar pipeline em duas etapas:
 - clustering para organização prévia;
 - classificação supervisionada sobre grupos ou subconjuntos;
- comparar pelo menos 3 algoritmos;
- comparar 2 embeddings;
- usar API para explicar clusters, rotular grupos ou justificar a combinação das etapas.

Resultados esperados:

- comparação entre pipeline direto e pipeline híbrido;
- análise dos grupos;
- discussão sobre redução de escopo/contexto.

Profundidade de pesquisa: esse tema puxa fortemente a ideia do plano de **filtragem local, clustering, repertórios e redução de contexto antes de etapas mais complexas**.

8. API experimental de NLP com múltiplos serviços

Pergunta central: como transformar experimentos de NLP em um artefato reutilizável?

Escopo:

- usar 2 bases;

- construir API em Flask/FastAPI com rotas como:
 - classificar texto,
 - buscar similares,
 - resumir textos,
 - explicar resultado;
- comparar 3 abordagens/modelos;
- comparar 2 embeddings;
- integrar ao menos 1 API externa de IA.

Resultados esperados:

- serviço funcional;
- documentação mínima;
- exemplos de chamadas;
- comparação entre rotas e modelos.

Profundidade de pesquisa: alinha-se com a produção de **artefatos reutilizáveis, APIs, repositórios, manuais e materiais de suporte.**

9. Benchmark local-first para NLP textual

Pergunta central: quais trade-offs aparecem entre modelos/abordagens mais leves e abordagens mais avançadas?

Escopo:

- usar 2 bases;
- comparar pelo menos:
 - modelo clássico leve,
 - modelo intermediário,
 - embedding/LLM mais avançado;
- medir:
 - qualidade,
 - tempo,
 - custo de execução,
 - simplicidade de uso;
- usar API para análise complementar, explicação ou refinamento.

Resultados esperados:

- benchmark comparativo;
- tabelas e gráficos;
- discussão sobre custo-benefício técnico.

Profundidade de pesquisa: esse tema se aproxima da lógica do Jurix atualizada, que enfatiza **benchmark, trade-offs, soberania computacional, modelos locais e avaliação técnica.**

10. Framework experimental de NLP com representação intermediária e avaliação reprodutível

Pergunta central: como organizar um framework experimental de NLP que seja comparável, documentado e reutilizável?

Escopo:

- usar 2 bases;
- definir pipeline modular com:
 - ingestão,
 - pré-processamento,
 - embeddings,
 - clustering/classificação,
 - visualização,
 - explicação via API;
- comparar 3 algoritmos ou mais;
- comparar 2 embeddings;
- criar alguma forma de representação intermediária dos experimentos, como JSON, tabelas padronizadas ou logs.

Resultados esperados:

- framework experimental;
- caderno de experimentos;
- relatório de cenários;
- documentação reprodutível.

Profundidade de pesquisa: esse é o tema mais forte e mais acadêmico, porque incorpora:

- arquitetura,
- modularidade,
- representação intermediária,
- baselines,
- métricas,
- cenários,
- logs,
- reprodutibilidade.

Isso dialoga muito bem com o texto do André e com o material do Jurix.

Requisitos metodológicos padronizados para todos

Uma forma boa de fechar para a turma é colocar isso como regra geral:

Cada dupla deve entregar

- título;

- problema/objetivo;
- 2 bases utilizadas;
- descrição do pré-processamento;
- 2 tipos de embeddings;
- 3 algoritmos ou abordagens ou mais;
- comparação de parâmetros principais;
- métricas;
- visualizações;
- análise de erros ou análise qualitativa;
- uso de API;
- conclusão;
- limitações;
- possibilidades de continuidade.

Estrutura mínima esperada

- Notebook principal e códigos associados (ou toda estrutura .py e outros);
- README;
- Relatório docx;
- apresentação;
- pasta com resultados/figuras, arquivos e códigos. Implementações usando FastAPI ou outras formas, uso de bancos de dados e/ou interfaces ou serviços web serão valorizados.

O que será valorizado

- organização experimental;
- comparação bem feita;
- profundidade da análise;
- clareza metodológica;
- documentação;
- tentativa de produzir algo reprodutível e aproveitável.